TRABAJO FINAL · DATA ENGINEER · GRUPO 6

¿A qué 200 alumnos llama Tutorías?

UniAndina: una plataforma de datos para detectar a tiempo el riesgo de abandono

Revisión · Mati **Arquitectura** · [nombre] **Operación** · [nombre] **Gobierno** · [nombre]

PROBLEMA Y DECISIÓN

La decisión es a quién llamar. Para tomarla, los datos tienen que ser confiables, y no lo eran.

60

personas con dos legajos: contarían doble

0–100

la escala nueva de las notas de 2025-1c, que además cambiaron de columnas

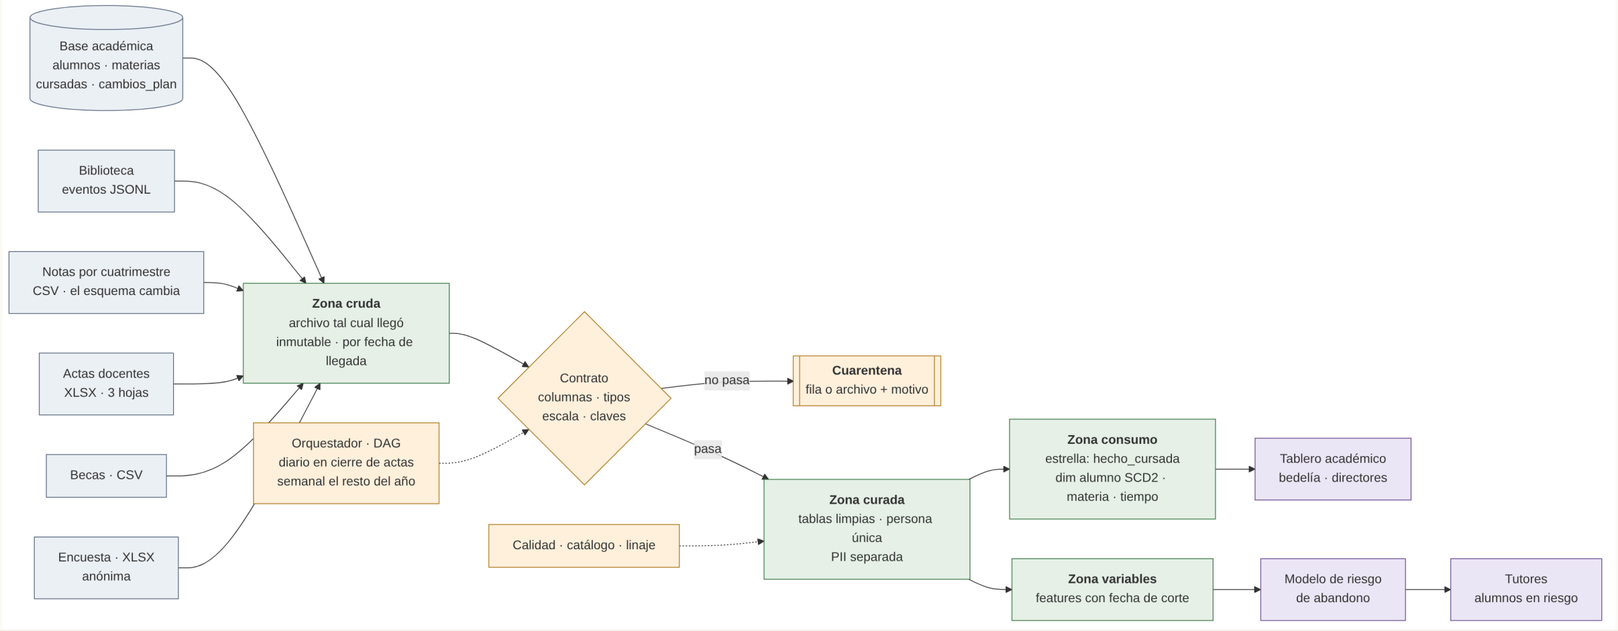
5

datos personales de estudiantes que hay que proteger

27 problemas medidos con código en las 7 fuentes, cada uno con su decisión · diagnóstico del notebook

EL DISEÑO · ARQUITECTURA

Lakehouse liviano: lo crudo intacto, lo demás en tablas



Elegido: si un archivo cambia de formato, el original sigue ahí para reprocesar

Descartado: warehouse clásico (pierde el original) y Spark (un clúster para 2,5 MB)

EL DISEÑO · MODELO Y CARGA

Una persona, no un legajo, y la historia de su plan

Dimensión alumno con historia (SCD 2)

La base pisa el plan viejo. Cada cambio cierra una versión y abre otra:

Plan 2018 · desde 1/8/2024 | Plan 2023 · vigente

Cada cursada usa el plan que el alumno tenía al inscribirse. Una sola versión vigente por persona: si no, la carga se revierte entera.

Medir antes y después · 100.000 personas

Fila por fila (como un cursor): 1,5 s



Por conjuntos, sin índice: 5,0 s



Por conjuntos, con índice: 0,6 s

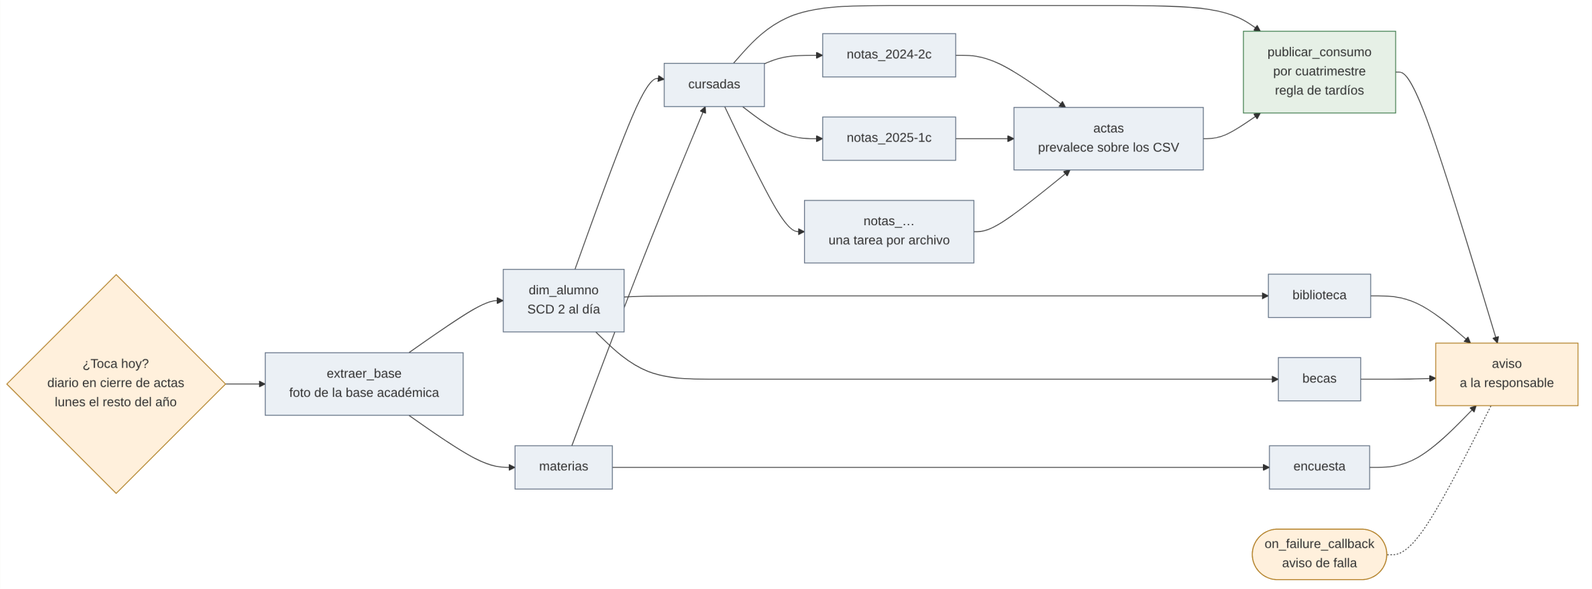


La primera versión «optimizada» era la más lenta. Lo vimos porque medimos.

Hecho: persona × materia × cuatrimestre · 12 de 12 restricciones rechazan los datos malos · módulos 2 y 3

EL DISEÑO · INGESTIÓN Y ORQUESTACIÓN

Cada origen con su contrato, cada corrida con su orden



Contrato v1 y v2, cada versión con su escala declarada

Cuarentena: el archivo si se rompe la forma, la fila si falla el dato

158 corridas en 2025: diarias en cierre de actas, los lunes el resto

LA EVIDENCIA · CALIDAD Y SEGURIDAD

6 de 10 reglas cumplen. Las 4 que fallan ahora tienen dueño.

Lo que fallan es el origen

- 3 % de las personas con dos legajos
- 25 cursadas de alumnos que no existen
- 55 cursadas con estado y nota contradictorios
- 6,25 % de becas de DNI que no son alumnos

42

alumnos figuran aprobados en la base y ausentes en el acta

Cada rol ve según su nivel

- 133 columnas clasificadas en 4 niveles
- Datos personales en una tabla aparte, con seudónimo
- Un nivel arriba se enmascara, dos se quita
- Tutorías: nombre y correo de sus 200, sin puntaje
- Cada acceso queda auditado, también los denegados

Dueño: un área de la universidad · responsable: quien decide cuando falla un control · módulos 6 y 9

LA EVIDENCIA · EL MODELO

Un modelo que no mira la respuesta

La trampa del caso

«Abandonó» una materia aparece solo en quienes abandonan. 209 de 247 ya lo tenían antes del corte.

0,95
AUC usándolo: detecta a quienes ya se fueron

0,70
AUC honesto, solo con lo anterior al corte

Dos candidatos contra la regla

Versión	Recall@200	Resultado
v0 · regla	0,174	respaldo
v1 · logística	0,186	rechazado
v2 · árboles	0,214	promovido

v2 encuentra un 23 % más de abandonos que la regla y le gana en las 5 repeticiones.

Corte 1/3/2025 · 2.000 personas, 247 abandonos · recall@200: de los que abandonan, cuántos quedan en la lista de 200 · módulo 7

FALLAS Y RECUPERACIÓN

Probamos tres fallas. Ninguna publicó nada a medias.

Archivo con columnas nuevas

Va entero a cuarentena. No se reintenta: fallaría igual. El tablero sigue con lo último bueno.

Módulos 4 y 5

Rectificación de un acta cerrada

Entra a la zona curada, pero el tablero sigue diciendo 6 hasta que la responsable reabre el cuatrimestre. Después dice 8.

Módulo 5

La biblioteca no informó julio

No estaba planeada. El monitoreo la detectó (PSI ≈ 3) y el modelo volvió solo a la regla de respaldo.

Módulo 7 · falla real

Todo es idempotente: reprocesar un día cualquiera no duplica nada · el reproceso forzado se probó en el módulo 4

LO QUE QUEDA ABIERTO

Cuatro cosas abiertas, con su primer paso

Qué queda abierto	Primer paso	Prioridad
El modelo es modesto: encuentra el 21 % de los abandonos	Confirmar con Biblioteca lo de julio y reentrenar con otra cohorte	1 y 3
42 alumnos aprobados y ausentes a la vez	Revisarlos con Bedelía	1
El contrato de notas lo cumplimos de un solo lado	Que lo firme la Dirección de Alumnos	1
SQLite es el único almacén: el mayor radio de impacto	Respaldo diario probado y un motor con roles reales	3

17 supuestos escritos con su porqué · backlog y matriz de riesgos completos en el módulo 10 del notebook