TRABAJO FINAL · DATA ENGINEER · GRUPO 6

¿A qué 200 alumnos llama Tutorías?

UniAndina: una plataforma de datos para detectar a tiempo el riesgo de abandono

PROBLEMA Y DECISIÓN

La decisión es a quién llamar. Para tomarla, los datos tienen que ser confiables, y no lo eran.

60

personas con dos legajos: contarían doble

0–100

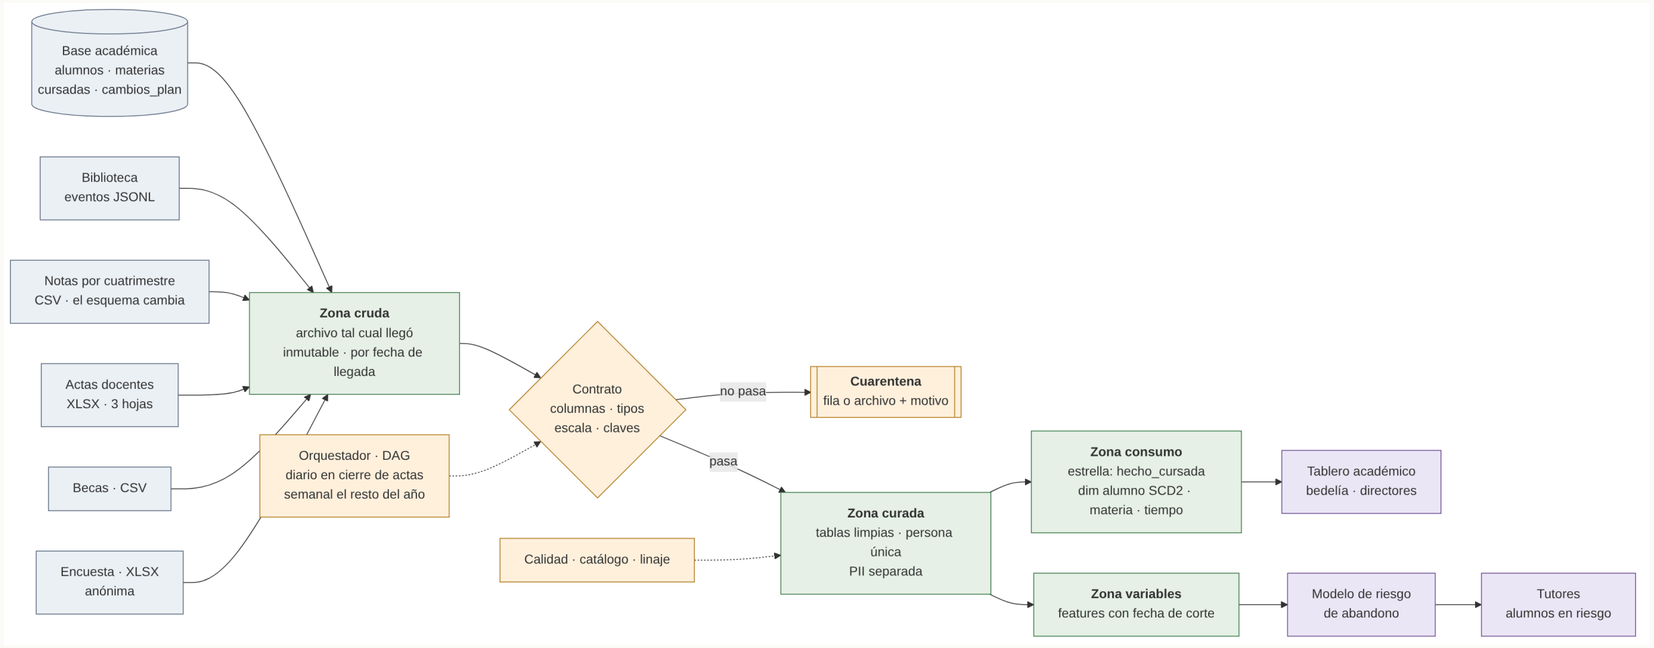
la escala nueva de las notas de 2025-1c, que además cambiaron de columnas

5

datos personales de estudiantes que hay que proteger

EL DISEÑO · ARQUITECTURA

Lakehouse



Elegido: si un archivo cambia de formato, el original sigue ahí para reprocesar

Descartado: warehouse clásico (pierde el original) y Spark (un clúster para 2,5 MB)

EL DISEÑO · MODELO Y CARGA

Una persona, no un legajo, y la historia de su plan

Dimensión alumno con historia (SCD 2)

Si un alumno cambia de plan de estudios, no pisamos su fila: la cerramos y abrimos otra.

Fila 1 · Plan 2018 · cerrada — queda como historia

Fila 2 · Plan 2023 · vigente — es la que rige hoy

Cada cursada usa el plan que el alumno tenía al inscribirse. Hay una sola fila vigente por persona: si la carga deja dos, se revierte entera.

Medir antes y después · 100.000 personas

Fila por fila (como un cursor): 1,5 s



Por conjuntos, sin índice: 5,0 s



Por conjuntos, con índice: 0,6 s



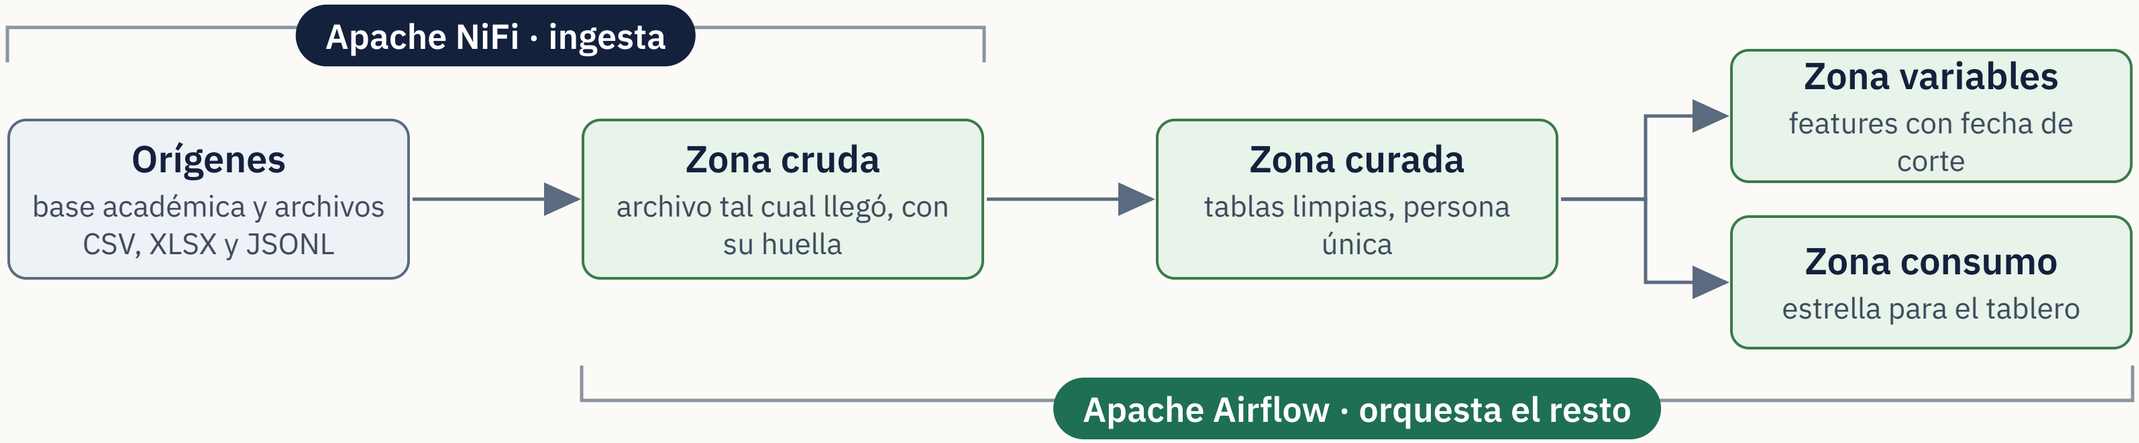
La primera versión «optimizada» era la más lenta. Lo vimos porque medimos.

Hecho: persona × materia × cuatrimestre · 12 de 12 restricciones rechazan los datos malos · módulos 2 y 3

EL DISEÑO · INGESTIÓN Y ORQUESTACIÓN

NiFi carga lo crudo, Airflow orquesta el resto

Trae cada archivo tal cual llegó; con su huella no ingiere dos veces lo mismo.



Un DAG con dependencias: a diario en cierre de actas, los lunes el resto del año.

NiFi: ingesta de los archivos a la zona cruda

Airflow: orquesta curada, variables y consumo

Cuarentena: el archivo si se rompe la forma, la fila si falla el dato

LA EVIDENCIA · CALIDAD Y SEGURIDAD

6 de 10 reglas cumplen. Las 4 que fallan ahora tienen dueño.

Lo que fallan es el origen

- 3 % de las personas con dos legajos
- 25 cursadas de alumnos que no existen
- 55 cursadas con estado y nota contradictorios
- 6,25 % de becas de DNI que no son alumnos

42

alumnos figuran aprobados en la base y ausentes en el acta

Cada rol ve según su nivel

- 133 columnas clasificadas en 4 niveles
- Datos personales en una tabla aparte, con seudónimo
- Un nivel arriba se enmascara, dos se quita
- Tutorías: nombre y correo de sus 200, sin puntaje
- Cada acceso queda auditado, también los denegados

Dueño: un área de la universidad · responsable: quien decide cuando falla un control · módulos 6 y 9

LA EVIDENCIA · EL MODELO

Un modelo que no mira la respuesta

La trampa del caso

«Abandonó» una materia aparece solo en quienes abandonan. 209 de 247 ya lo tenían antes del corte.

0,95
AUC usándolo: detecta a quienes ya se fueron

0,70
AUC honesto, solo con lo anterior al corte

Contra el azar y contra la regla

Versión	Recall@200	Resultado
v0 · azar	0,100	referencia
regla actual	0,174	respaldo
v1 · logística	0,186	rechazado
v2 · árboles	0,214	promovido

v0 es llamar a 200 de 2.000 alumnos al azar: se espera encontrar el 10 % de los abandonos. v2 encuentra más del doble y le gana a la regla en las 5 repeticiones.

Corte 1/3/2025 · 2.000 personas, 247 abandonos · recall@200: de los que abandonan, cuántos quedan en la lista de 200 · módulo 7

FALLAS Y RECUPERACIÓN

Probamos tres fallas. Ninguna publicó nada a medias.

Archivo con columnas nuevas

Va entero a cuarentena. No se reintenta: fallaría igual. El tablero sigue con lo último bueno.

Módulos 4 y 5

Rectificación de un acta cerrada

Entra a la zona curada, pero el tablero sigue diciendo 6 hasta que la responsable reabre el cuatrimestre. Después dice 8.

Módulo 5

La biblioteca no informó julio

No estaba planeada. El monitoreo la detectó y el modelo volvió solo a la regla de respaldo.

Módulo 7 · falla real

Todo es idempotente: reprocesar un día cualquiera no duplica nada · el reproceso forzado se probó en el módulo 4

LO QUE QUEDA ABIERTO

Futuros Pasos

Qué queda abierto	Primer paso	Prioridad
El modelo es modesto: encuentra el 21 % de los abandonos	Confirmar con Biblioteca lo de julio y reentrenar con otra cohorte	1 y 3
42 alumnos aprobados y ausentes a la vez	Revisarlos con Bedelía	1
SQLite es el único almacén: el mayor radio de impacto	Respaldo diario probado y un motor con roles reales	3

17 supuestos escritos con su porqué · backlog y matriz de riesgos completos en el módulo 10 del notebook