TRABAJO FINAL · DATA ENGINEER · GRUPO 6

¿A qué 200 alumnos llama Tutorías?

UniAndina: una plataforma de datos para detectar a tiempo el riesgo de abandono

PROBLEMA Y DECISIÓN

La decisión es a quién llamar. Para tomarla, los datos tienen que ser confiables, y no lo eran.

60

personas con dos legajos: contarían doble

0–100

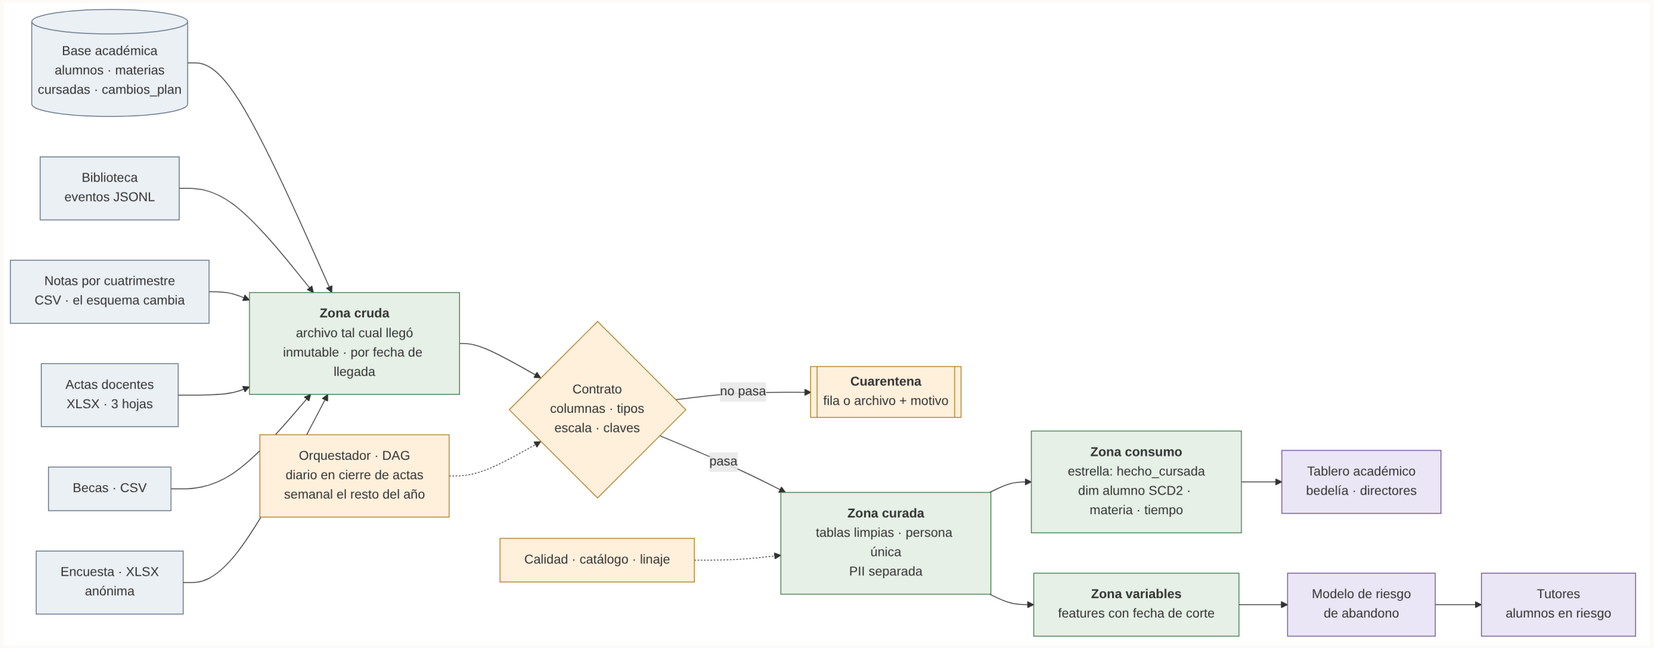
la escala nueva de las notas de 2025-1c, que además cambiaron de columnas

5

datos personales de estudiantes que hay que proteger

EL DISEÑO · ARQUITECTURA

Lakehouse



Elegido: si un archivo cambia de formato, el original sigue ahí para reprocesar

Descartado: warehouse clásico (pierde el original) y Spark (un clúster para 2,5 MB)

EL DISEÑO · MODELO

Una persona, no un legajo, y la historia de su plan

La **dimensión alumno** guarda una fila por cada plan de carrera que tuvo la persona. Si cambia de plan, no pisamos su fila: la cerramos y abrimos otra.

EJEMPLO ILUSTRATIVO: UNA PERSONA QUE CAMBIA DE PLAN

Fila	Persona (DNI)	Plan de carrera	Vigente desde	Vigente hasta	¿Vigente?
1	Persona 1042	**Plan 2018**	1/8/2024	19/2/2025	**no, cerrada**
2	Persona 1042	**Plan 2023**	20/2/2025	—	**sí**

CADA CURSADA USA EL PLAN QUE LA PERSONA TENÍA AL EMPEZAR EL CUATRIMESTRE

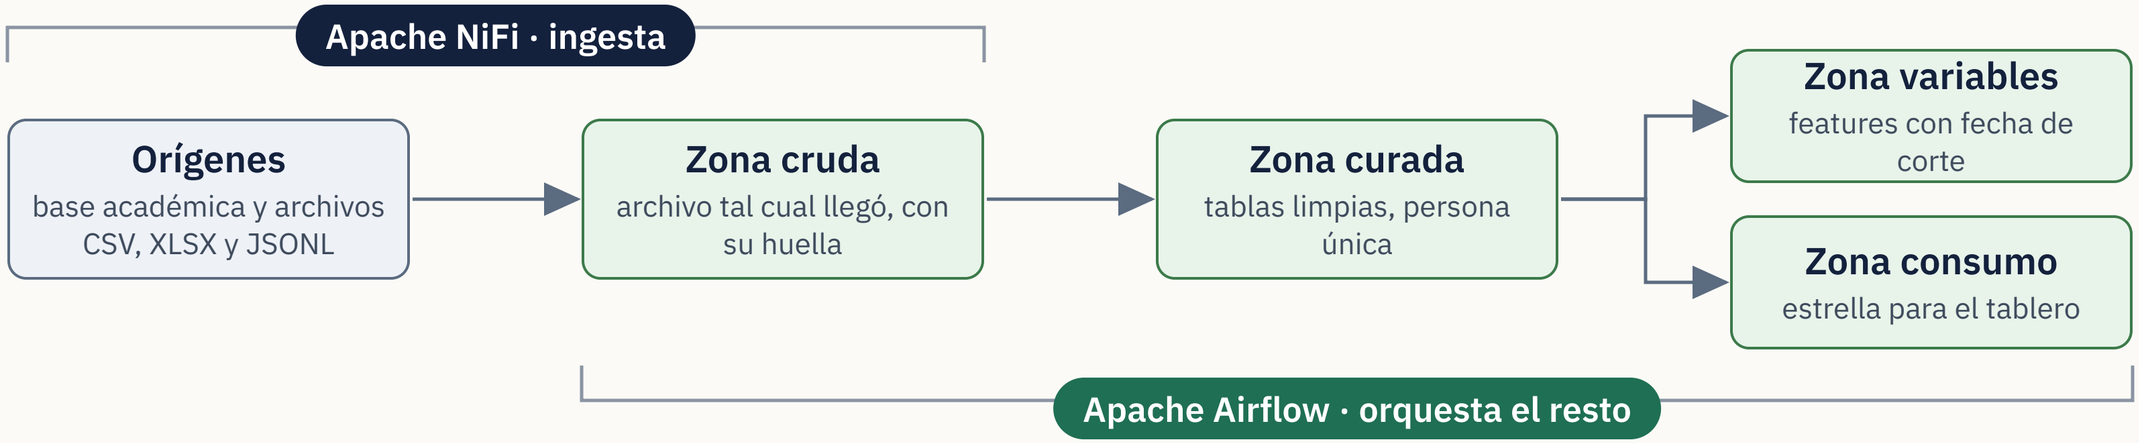
Cursada 2024-2c · empieza el 1/8/2024
usa la fila 1: Plan 2018

Cursada 2025-1c · empieza el 1/3/2025
usa la fila 2: Plan 2023

EL DISEÑO · INGESTIÓN Y ORQUESTACIÓN

NiFi carga lo crudo, Airflow orquesta el resto

Trae cada archivo tal cual llegó; con su huella no ingiere dos veces lo mismo.



Un DAG con dependencias: a diario en cierre de actas, los lunes el resto del año.

NiFi: ingesta de los archivos a la zona cruda

Airflow: orquesta curada, variables y consumo

Cuarentena: el archivo si se rompe la forma, la fila si falla el dato

LA EVIDENCIA · CALIDAD

6 de 10 reglas cumplen. Las 4 que fallan ahora tienen dueño.

R1	**Una sola versión vigente por persona** cumple · umbral 0 casos	**R6**	**Acta y CSV coinciden en las notas** cumple · umbral ≥ 99 %
R2	**Personas con dos legajos** **mide 3 % · umbral 1 %**	**R7**	**Becas con DNI de un alumno** **6,25 % sin alumno · umbral 5 %**
R3	**Cursadas de alumnos que no existen** **25 cursadas (0,16 %) · umbral 0,1 %**	**R8**	**Respuestas de la encuesta válidas** cumple · umbral ≥ 95 %
R4	**Estado de la cursada contradice la nota** **55 cursadas, 42 aprobados y ausentes · umbral 0,1 %**	**R9**	**Actas cargadas en menos de 24 horas** cumple · umbral 24 h
R5	**Cursadas terminadas con nota o ausente** cumple · umbral ≥ 99 %	**R10**	**Balance de lotes cierra** cumple · umbral 100 %

Naranja: reglas que no se cumplen · dueño: un área de la universidad · responsable: quien decide cuando falla un control · módulo 6

LA EVIDENCIA · EL MODELO

Un modelo que no mira la respuesta

La trampa del caso

«Abandonó» una materia aparece solo en quienes abandonan. 209 de 247 ya lo tenían antes del corte.

0,95
AUC usándolo: detecta a quienes ya se fueron

0,70
AUC honesto, solo con lo anterior al corte

Dos candidatos contra el azar

Versión	Recall@200	Resultado
v0 · azar	0,100	referencia
v1 · logística	0,186	rechazado
v2 · árboles	0,214	promovido

v0 es llamar a 200 de 2.000 alumnos al azar: se espera encontrar el 10 % de los abandonos. v2 encuentra más del doble.

Corte 1/3/2025 · 2.000 personas, 247 abandonos · recall@200: de los que abandonan, cuántos quedan en la lista de 200 · módulo 7

FALLAS Y RECUPERACIÓN

Probamos tres fallas. Ninguna publicó nada a medias.

Archivo con columnas nuevas

Va entero a cuarentena. No se reintenta: fallaría igual. El tablero sigue con lo último bueno.

Módulos 4 y 5

Rectificación de un acta cerrada

Entra a la zona curada, pero el tablero sigue diciendo 6 hasta que la responsable reabre el cuatrimestre. Después dice 8.

Módulo 5

La biblioteca no informó julio

No estaba planeada. El monitoreo la detectó y el modelo volvió solo a la regla de respaldo.

Módulo 7 · falla real

Todo es idempotente: reprocesar un día cualquiera no duplica nada · el reproceso forzado se probó en el módulo 4

LO QUE QUEDA ABIERTO

Futuros Pasos

Qué queda abierto	Primer paso	Prioridad
El modelo es modesto: encuentra el 21 % de los abandonos	Confirmar con Biblioteca lo de julio y reentrenar con otra cohorte. Sumar más casos para entrenar, incluso de otras universidades	1 y 3
42 alumnos aprobados y ausentes a la vez	Revisarlos con el Departamento de Alumnos	1
SQLite es el único almacén: el mayor radio de impacto	Respaldo diario probado y un motor con roles reales	3

17 supuestos escritos con su porqué · backlog y matriz de riesgos completos en el módulo 10 del notebook